

Previsão de Tendências de Preços de Ações com a WiSARD

Aluno: Cleiton Moya de Almeida

Disciplina: CPS841 – Redes Neurais Sem Peso

Prof.: Priscila Vieira Machado Lima

Apresentado em: 16/07/2020

Revisão final: 21/07/2020


Agenda

1. Motivação
2. Breve Revisão da Literatura
3. Objetivo
4. Construção da Retina
5. Rotulagem
6. Treinamento e Ajustes
7. Resultados
8. Conclusão

Motivação

- **Quantitative Trading:**

- ✓ 80% dos negócios no mercado futuro dos EUA são realizados por robôs de alta frequência (HFT) (Jansen, 2018);
- ✓ **2017**: fundos *quants* cresceram 15% ao ano desde 2011 e controlaram **US\$ 1,5 trilhões** (Jansen, 2018);
- ✓ **Medallion Fund**: 39%a.a. de 1988 a 2018;



Jim Simons – “The man who solved the market”

- **Machine Learning em Finanças:**

- ✓ Séries temporais financeiras:
 - Hipótese do Mercado Eficiente - passeio aleatório:
 - $Y_{t+1} = Y_t + \varepsilon$, onde ε é um ruído aleatório.
- ✓ Dificuldades no teste / validação:
 - Ex.: *K-fold* não se aplica;
- ✓ Maioria dos algoritmos fracassam na prática (Prado, 2019);
- ✓ Estratégias de sucesso não são divulgadas.
- ✓ “Uma taxa de acerto 52% pode parecer modesta, mas se for consistente você pode fazer muito dinheiro” (Mustafa, Y., 2012).

The World’s Top Investors

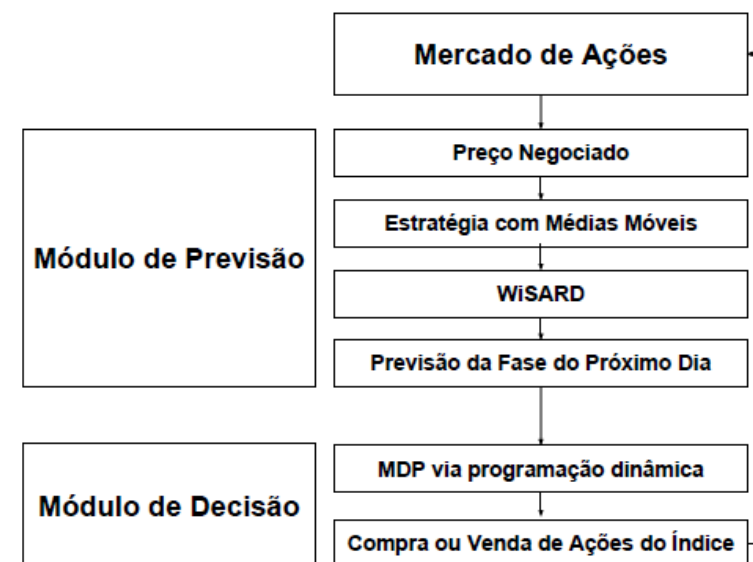
Investor, Key Fund/Vehicle	Period	Average Annual Returns After Fees
Jim Simons, Medallion	1988-2018	39%
George Soros, Quantum	1969-2000	32%
Steven Cohen, SAC	1992-2003	30%
Peter Lynch, Magellan	1977-1990	29%
Warren Buffett, Berkshire Hathaway	1965-2018	21%
Ray Dalio, Pure Alpha	1991-2018	12%

Source: The Wall Street Journal

www.libertythroughwealth.com

Breve Revisão da Literatura

- **Dois problemas principais:**
 - ✓ Previsão de preços ou retornos: regressão;
 - ✓ Previsão da tendência (movimento): classificação.
- **Tipos de Dados (Prado, 2018):**
 - ✓ Dados de mercado (*raw data*);
 - ✓ Dados analíticos (derivados);
 - ✓ Dados alternativos (Ex.: Ocupação de estacionamentos)
- **Séries temporais financeiras com WiSARD:**
 - ✓ Samara Alves (2017) utilizou a WiSARD para a previsão de tendências;
 - ✓ **6 fases:** Recuperação, Acumulação, Altista, Aviso, Distribuição, Baixista;
 - ✓ Utilização somente do **preço de fechamento** para o cálculo das fases;
 - ✓ Rotulagem com base nestas 6 regiões;
 - ✓ Retina: fases dos **5 dias anteriores**;



Estratégia testada por Samara Alves (2017)

Objetivos

- **Proposta**

- ✓ Explorar a WiSARD para a predição de tendências de ações com para o horizonte de negociação em dias (*swing trading*);
- ✓ 3 ações: BBDC4, PETR4, VALE3;
- ✓ *Features*:
 - Indicadores da Análise Técnica
 - Calculados a partir de dados de mercado:
 - Preço de abertura, máx., mín., fechamento e volume.
- ✓ *Banchmarking*: (Alves, 2017).
- ✓ Base de dados:
 - ✓ Dados de mercado extraídos da plataforma *ProfitChart Clear Trader*®.

- **Inspiração:**

“Backtesting não é uma ferramenta de pesquisa. Análise de importância de atributos é.

M. L. Prado in *Advances on Financial Machine Learning*

Construção da Retina

- **Indicadores técnicos⁽¹⁾:**
 - ✓ 11 indicadores: volume, tendência, média móvel, Bandas de Bollinger, MACD, RSI, Canal de Donchian, Canal de Keltner, ADX, Aroon;
 - ✓ 20 parâmetros associados;
 - ✓ Geração de **28 sinais de saída binários** para cada instante t ;
 - ✓ Exemplos de sinais:
 - Volume de negociações está crescente?
 - Houve cruzamento de médias móveis?
 - Bandas de Bollinger indicam compra?
- **Janela móvel:**
 - ✓ Cada instante de tempo t da série é representada por uma sequência de T dias anteriores:
 - $S[t] = \{E[t], E[t - 1], \dots, E[t - T]\}$
 - ✓ Retina: até **28 x T bits**



Exemplos de indicadores técnicos

Fonte: <https://br.tradingview.com>

(1) Detalhes sobre indicadores técnicos podem ser encontrados no livro de Flávio Lemos: **Análise Técnica dos Mercado Financeiros**. 2018.

Rotulagem

- **Abordagem testada inicialmente:**
 - ✓ 3 classes baseadas no retorno no horizonte h :
 - Tendência de baixa ($retorno < R_1$);
 - Tendência neutra ($R_1 \leq retorno < R_2$)
 - Tendência de alta ($retorno \geq R_2$)
 - ✓ Constatação na prática:
 - Elevado desequilíbrio;
 - Tendência neutra com poucos exemplares;
- **Abordagem selecionada:**
 - ✓ Apenas 2 classes;
 - ✓ $Preço(t + h) \leq Preço(t)$:
 - Tendência de baixa (0)
 - ✓ $Preço(t + h) > Preço(t)$:
 - Tendência de alta (1)

Treinamento e Ajustes

- **Treinamento:**

- ✓ Estratégia “*online*”:
 - Após a classificação de um exemplar da fase de teste, independente do resultado, a rede é treinada com este exemplar antes de uma nova classificação;
- ✓ Tempos de treinamento e classificação da **ordem de milissegundos**.

- **Parâmetros da WiSARD:**

- ✓ Utilização de Bleaching;
- ✓ Tamanho de endereçamento testados: [4, 8, 16, 24]
- ✓ Selecionado para testes: 4

- **Janela deslizante e horizonte de predição:**

- ✓ Janelas testadas: [1, 3, 5, 15]
- ✓ Janela selecionada para testes: 3
- ✓ Horizontes testados: [1, 3, 5, 10]
- ✓ Horizonte selecionado para testes: 3

- **Parâmetros dos Indicadores:**

- ✓ Busca heurística realizada com o ativo BBDC4;
- ✓ Combinações desejadas: $3^{20} = 3.486.784.401$
- ✓ Tentou-se testar: $4^3 \times 3^7 = 139.968$
 - Se cada teste durasse 1s, seriam necessárias ~39h
 - Após 8 horas, a busca foi interrompida.

- Testaram-se diversas combinações de parâmetros, algumas aparentavam melhores resultados. Porém:
- Após a execução de 1000 experimentos, verificou-se que os parâmetros testados **pouco influenciam a acurácia média**.

Resultados

- **Predição de tendências**

- ✓ **Acurácia:**

	(Alves, 2017)* 2008 a 2015	Este trabalho 2008 a 2015	Este trabalho 2015 a 2020
BBDC4	40,21%	(50,9 ± 2,2) %	(53,6 ± 2,6) %
PETR4	65,26%	(51,8 ± 2,0) %	(49,5 ± 3,5) %
VALE3	55,09%	(52,0 ± 2,3) %	(51,2 ± 2,7) %

*Tabela 9, classificador WiSARD

- ✓ **Matrizes de confusão:**

	BBDC4 2015 a 2020		PETR4 2015 a 2020		VALE3 2015 a 2020	
Baixa [0]	0,55	0,45	0,58	0,42	0,32	0,68
Alta [1]	0,48	0,52	0,40	0,60	0,26	0,74

- Após 1000 execuções para o cálculo da média e desvio-padrão:
 - **50%, considerando o limite de erro;**
 - **Acurácias não satisfatórias.**
- Melhor resultado para **BBDC4**;
- Maior dificuldade de previsão de tendência de baixa em **VALE3**;
- *Bias* pode ser explorado em algoritmos negociadores.

Resultados


• Comparação

• (Alves, 2017):

- ✓ Saída predita / rótulos: fases calculadas com base nas médias móveis não necessariamente refletem a tendência real;
- ✓ 6 rótulos;

Preços subindo,
porém fase é
"Baixa"

Preços caindo,
porém fase é
"Alta"




Saída real x predita (Alves, 2017)

(Fonte: gráfico gerado pelo autor com base no trabalho de Alves).

• Este trabalho:

- ✓ Saída predita / rótulos: tendência "real";
- ✓ "Alta": sempre implica preço crescente;
- ✓ Apenas 2 rótulos;
- ✓ Maior complexidade: requer maior conhecimento;



Saída real x predita –Proposta testada neste trabalho

Resultados


- **Estratégia simples negociação**

- ✓ A fim de melhor comparar os resultados com o trabalho de Alves (2017), definiu-se um agente negociador simples:
 - Caso a **tendência prevista seja de alta**:
 - Se não tiver posicionado, compra;
 - Senão, mantém;
 - Caso a **tendência prevista seja de baixa**:
 - Se tiver comprado, vende.
- ✓ Alves (2017) denominou esta estratégia de “Mercado”, e também implementou outra estratégia utilizando um modelo Processo de Decisão de Markov (MDP).

- **Estratégia *Buy & Hold***

- ✓ Implementou-se também a estratégia *Buy & Hold*:
 - Compra;
 - Mantém a posição por tempo indeterminado.

Obs.: Implementou-se este agente para caso se conseguisse acurácia satisfatória com o modelo. Como as acurácias não foram satisfatórias, o agente não é capaz de gerar lucro de forma consistente.



Resultados

- Retorno financeiro (*backtesting*)

	02/01/2008 a 30/06/2015 ¹				01/1/2015 a 31/01/2020	
	<i>Buy & Hold</i>	<i>Alves (2017) Estrat. "Mercado"</i>	<i>Alves (2017) Estrat. "MDP"</i>	<i>Este trabalho</i>	<i>Buy & Hold</i>	<i>Este trabalho</i>
BBDC4	8,9%	-4,5%	+29,9%	$+(17,2 \pm 20,5)\%$	-3,7%	$+(4,7 \pm 9,1)\%$
PETR4	-26,0%	-45,6%	-26,6%	$+(2,6 \pm 30,1)\%$	10,9%	$-(0,7 \pm 11,0)\%$
VALE3	-34,2%	-86,6%	-5,7%	$-(9,3 \pm 16,9)\%$	24,8%	$+(28,3 \pm 20,5)\%$

(1) Os períodos de teste não foram exatamente iguais nos dois trabalhos devido a diferenças no split da base de dados;

- Conforme esperado, ↓ **acurácia na prev. da tendência** → ↑ **desvio padrão**;
- Como as acurácias não foram satisfatórias, o agente não é capaz de gerar lucro de forma consistente

Conclusões

- O modelo proposto neste trabalho **não apresentou acurácia satisfatória** para a predição de tendências de ações;
- Uma hipótese para a baixa acurácia é que a **complexidade do sinal de saída** (rótulos) demanda um alto grau de informação para a predição, e os sinais binários utilizados neste trabalho não são capazes de prover este grau de informação;
- Como sugestão para trabalho futuros, seria importante fazer uma análise mais criteriosa da **importância e influência de cada *feature*** no modelo, bem como suas correlações, de modo a verificar como se pode aumentar o nível de informação de cada feature;
- Caso se consiga uma acurácia satisfatória, como em (Alves, 2017), a WiSARD é bastante atrativa para a área de *Quantitative Trading* devido à sua **rapidez e simplicidade**.

Bibliografia

- Alves, Samara. A. Negociação no mercado financeiro utilizando a rede neural sem peso WiSARD. **Dissertação de mestrado**. 2017.
- George S. Atsalakis, Kimon P. Valavanis. **Surveying stock market forecasting techniques** – Part II: Soft computing methods, Expert Systems with Applications, Volume 36, Issue 3, Part 2. Disponível em: <https://doi.org/10.1016/j.eswa.2008.07.006>.
- Mustafa, Y. **Learning from Data**. 2012.
- Kofi Nti et. al. **A systematic review of fundamental and technical analysis of stock market predictions**. Disponível em: <https://doi.org/10.1007/s10462-019-09754-z>
- Jansen, Stefan. **Hands On Machine Learning for Alghoritmik Trading**. Packet, 2018.
- Prado, Marcos López. **Advances in Financial Machine Learning**. Wiley, 2017.